

Desafio Lighthouse

Dados e IA

Leia as instruções com atenção.

Ajuste de Zoom: Se precisar aumentar ou diminuir o tamanho do texto, pressione Ctrl e + (Aumentar) ou Ctrl e - (Diminuir) no teclado. Para retornar ao tamanho original, pressione Ctrl e 0. (No Mac, utilize a tecla Cmd no lugar de Ctrl). Você também pode alterar o tamanho da fonte diretamente nas configurações do seu sistema operacional.

Modo Escuro e Luz Azul: Caso prefira a tela escura, você pode ativar o modo de alto contraste do seu sistema operacional. Para suavizar a visualização e diminuir o cansaço visual, ative o modo de Luz Noturna (Windows) ou Night Shift (Mac).

Atenção

Nesta etapa do desafio, você terá **7 dias (até 17/08, às 08h)** para consultar o enunciado, acessar as questões por meio do botão **"Responder às questões"** e preparar suas respostas. **Você poderá entrar e sair do ambiente quantas vezes desejar** antes de iniciar o preenchimento.

Atenção: o questionário permite apenas **uma única tentativa e não salva automaticamente as respostas**.

Por isso, recomendamos que você elabore suas respostas em um rascunho e as **registre na plataforma apenas quando estiver tudo pronto**. Clique em **"Enviar"** somente após revisar e concluir todas as respostas, pois não será possível editar ou realizar uma nova submissão.

Desejamos boa sorte nesta etapa.

Qualquer dúvida, entre em contato pelo e-mail academy@indicium.ai

Introdução

Este desafio tem como objetivo avaliar sua aptidão para atuar na jornada de dados da LH Nautical, testando sua capacidade analítica, domínio técnico, visão de negócio e pragmatismo. Buscamos entender seu raciocínio de ponta a ponta: desde o tratamento de dados brutos e modelagem SQL até a geração de insights estratégicos e aplicação de lógica preditiva.

Não avaliamos apenas o código, mas a sua habilidade de transformar dados desorganizados em soluções que gerem valor real para a operação. Responda a todas as etapas com base no contexto fictício da LH Nautical descrito abaixo, seguindo as orientações do Tech Lead, Gabriel Santos.

Contexto Fictício

Sobre a Empresa

A LH Nautical é uma empresa de varejo náutico com lojas físicas, armazéns e canal de e-commerce. Seus dados operacionais cobrem o período de 2020 a 2026 e registram o ciclo completo: catálogo de produtos, pedidos de venda, pagamentos, nota fiscal eletrônica, compras de fornecedores, movimentação de estoque e devoluções.

Você terá acesso a 24 arquivos CSV na pasta `lh_nautical_csv/`, representando o schema relacional da empresa. Sua missão é percorrer as etapas de um pipeline de dados real, da ingestão bruta à inteligência aplicada.

Stakeholders Principais

Durante o desafio, você irá interagir com as necessidades de três perfis centrais da empresa:

- **Gabriel Santos (Tech Lead):** O mentor técnico que valoriza a organização, a documentação e a clareza do raciocínio acima de códigos complexos.
- **Marina Costa (Gerente de Negócios):** Focada em resultados práticos, margens de lucro e performance de vendas.
- **Sr. Almir (Fundador):** Representa a visão old school; ele desconfia da "nuvem" e precisa ser convencido por dados sólidos e análises precisas.

Seu Objetivo

Você acaba de receber um e-mail do Gabriel Santos, Tech Lead da LH Nautical. A empresa vai lançar uma campanha na semana que vem, mas os dados estão completamente desorganizados. Sua missão é limpar as bases, estruturar as tabelas e gerar os relatórios que a diretoria exige. Mas o Gabriel avisou: "Eu valorizo mais a organização e a explicação do que o código rodando sem eu entender nada." Sua missão é atuar como o profissional de dados que transformará esse cenário. Você terá acesso a bases brutas (como o catálogo de produtos e históricos de vendas) e deverá realizar desde a limpeza e modelagem (Engenharia de Dados e SQL) até a geração de insights preditivos e sistemas de recomendação (Ciência de Dados e IA).

Formato de Entrega:

As entregas foram separadas em frentes de:

- EDA
- Tratamento de dados
- Análise de vendas
- Análise de Clientes
- Previsão de demandas
- Sistemas de recomendações

E as solicitações estão organizadas nas questões desse desafio, **você deve interpretar as perguntas e responder cada questão com base nas suas análises seguindo as premissas obrigatórias.**

Ao final do desafio, você **DEVERÁ** enviar um material complementar (painel/dashboard) com visualizações que ajudem a comunicar os principais resultados das análises realizadas no desafio. O envio é no formato que desejar e será realizada no campo 20 - [Espaço para adicionar arquivos \(PDFs, Pbix, CSVs...\)](#).

Sugestões de visuais para o dashboard/relatório:

- Distribuição ou ranking de prejuízos por produto (questão 4)
- Gráfico dos clientes com maior lucro acumulado (questão 5)
- Vendas médias por dia da semana considerando dias sem venda (questão 6)
- Explorações adicionais relevantes

O objetivo é demonstrar como você organiza e comunica insights a partir dos dados.

Questão 1 - EDA

Cenário

Antes de qualquer análise, modelagem ou tomada de decisão, é fundamental entender o que existe nos dados. O Sr. Almir quer uma resposta simples: “Posso confiar nesses dados para tomar decisões?”

Sua missão é **realizar uma análise exploratória inicial nas tabelas** e responder perguntas básicas, porém críticas, sobre volume, distribuição e qualidade dos dados.

Premissas obrigatórias

- Utilize apenas a tabela "[orders](#)"
- Não faça limpeza nem tratamento dos dados
- Apenas observe, agregue e descreva

Tarefas:

Parte 1 - Visão geral da tabela `orders`

Informe:

- Quantidade total de linhas
- Quantidade total de colunas
- Intervalo de datas analisado (data mínima e máxima) da coluna `created_at`

Parte 2 - Análise de valores numéricos

Para a coluna `"total"`, calcule:

- Valor mínimo
- Valor máximo
- Valor médio

Parte 3 - Interpretação

Responda de forma resumida:

Com base na análise exploratória realizada, escreva um breve diagnóstico sobre a confiabilidade da tabela `orders` para análises futuras.

Comente sobre:

- possíveis outliers em `"total"`,
- qualidade dos dados (valores nulos ou inconsistentes),
- e se você considera que o dataset está pronto para análises ou se exigiria tratamento prévio.

Questão 1.1 - SQL

Código calculando:

- Quantidade total de linhas
- Intervalo de datas analisado (data mínima e máxima)
- Valor mínimo
- Valor máximo
- Valor médio

Questão 1.2 - Validação

Qual é o valor médio registrado na coluna `"total"`?

Questão 1.3 - Interpretação

Com base na análise exploratória realizada, escreva um breve diagnóstico sobre a confiabilidade da tabela `orders` para análises futuras. Comente sobre:

- Possíveis outliers em `"total"`,
- Qualidade dos dados (valores nulos ou inconsistentes),
- e se você considera que a tabela `orders` está pronta para análises ou se exigiria tratamento prévio ou relacionamento com demais tabelas?

Questão 2 - Schema

Cenário

Você foi informado que a empresa que fornece os serviços do ERP não permite conexão direta com o banco de dados e a única forma de se obter os dados é através dos CSVs já fornecidos.

Para realizar as próximas etapas precisaremos desses dados carregados em algum banco de dados e, para isso, precisamos definir o schema desse banco primeiro. Sua missão é desenvolver um código que detecta as colunas de cada tabela a partir dos CSV e cria um arquivo final .sql com as instruções de criação de cada tabela.

Premissas obrigatórias

- Considere todos os CSV como arquivos de fonte.
- Utilize obrigatoriamente Python 3.
- Utilize somente bibliotecas padrão do Python 3 (csv, os, datetime e etc.) e python puro. Soluções que utilizarem bibliotecas como pandas, dask, polars serão desconsideradas.
- Considere o banco de destino como sendo um PostgreSQL.

Tarefa:

- Crie um script python que possa ler os CSV de um diretório e gere um único arquivo de saída (**schema.sql**) com as instruções de criação de uma tabela para cada arquivo CSV usando somente bibliotecas de acordo com as instruções anteriores.

Questão 2.1 -

Faça o upload de seu código Python

Questão 2.2 -

Faça o upload de seu schema.sql com as instruções de criação das tabelas

Questão 3 - Carregamento

Cenário

Após a criação do schema é necessário realizar o carregamento desses dados nesse banco de dados brutos para facilitar as análises posteriores.

Premissas obrigatórias

- Realize o carregamento de todos os CSVs.
- Utilize obrigatoriamente Python 3.
- Utilize qualquer biblioteca necessária (nativa ou externa) para conexão e carregamento dos dados.
- Não faça tratamentos como: Remoção de nulos ou correção de caracteres especiais

Tarefa:

- Escreva um script python para realizar o carregamento de todos os arquivos CSV respeitando o schema criado na questão anterior.

Questão 3.1 -

Faça o upload de seu código Python

Questão 3.2 - Validação

Qual o total de linhas somadas das seguintes tabelas: customers, orders, order_items e payments?

Questão 4 - Análise de clientes

Cenário

A Diretoria da LH Nautical deseja identificar os clientes fieis. Diferente de quem compra muito uma única vez, o cliente fiel é o cliente que possui um gasto médio alto por transação e navega por diversas categorias da loja. O objetivo é mapear o que esses clientes de elite estão consumindo para replicar o comportamento em outros segmentos.

Premissas obrigatórias:

- Faturamento Total: Soma da coluna total por cliente.
- Frequência: Contagem total de transações (IDs de venda) por cliente.
- Ticket Médio: Faturamento Total / Frequência.
- Diversidade de Categorias: Quantidade de categorias distintas (category_id) que o cliente comprou.
- Filtro de Elite: Apenas clientes que compraram produtos de 13 ou mais categorias distintas devem ser considerados no ranking.
- Desempate: Em caso de empate no Ticket Médio, utilize o customer_id em ordem crescente.

Tarefa:

1. Calcule o Ticket Médio e a Diversidade de Categorias para cada customer_id.
2. Filtre os 10 clientes com o maior Ticket Médio que atendam ao critério de diversidade (13 ou + categorias).
3. Para este grupo específico de 10 clientes, identifique qual categoria de produto concentra a maior quantidade total de itens comprados (sum(quantity)).

Questão 4.1 - Código SQL

Código calculando:

- O Ticket Médio e a Diversidade de categorias por cliente.
- A identificação e filtro dos 10 clientes "Fiéis" (maior Ticket Médio entre aqueles com diversidade ≥ 13 categorias).

Questão 4.2 - Explique:

1. Como você chegou nas categorias mais vendidas? (mapeamento da cadeia de chaves)
2. Qual lógica utilizou para filtrar os clientes com diversidade mínima?
3. Como garantiu que a contagem de itens refletisse apenas os Top 10?

Questão 5 - Dimensão de calendário

Cenário

O Sr. Almir quer saber: "Qual é o dia da semana (Segunda, Terça...), nas lojas físicas, temos a pior média de vendas?" para decidir se vale a pena fechar a loja nesses dias.

Um estagiário fez um GROUP BY dia_semana direto na tabela de vendas e disse que o Domingo era ótimo, com média de R\$5.000,00.

O problema: O estagiário esqueceu que em muitos Domingos a loja abriu mas vendeu zero. Como esses dias não existem na tabela de vendas (orders), eles foram ignorados no cálculo da média, inflando o resultado. Precisamos corrigir isso utilizando um calendário de datas (dimensão de datas)

Premissas obrigatórias:

- O período de análise deve considerar todas as datas entre a menor e a data atual da venda presentes no arquivo.
- A loja esteve aberta em todos os dias do período (inclusive fins de semana).
- Considere apenas as lojas físicas (= pos)
- Dias sem registro na tabela de vendas devem ser considerados como valor da venda = 0.
- "Vendas diárias" correspondem à soma do valor da venda por dia.
- A média de vendas por dia da semana deve considerar todos os dias do calendário, inclusive os dias sem venda.
- O nome do dia da semana deve ser apresentado em português (Segunda-feira, Terça-feira, etc.).

Tarefa:

1. Construa uma dimensão de datas utilizando sql
2. Cruze a dimensão de datas com a tabela de vendas para análise.

Questão 5.1 - Código SQL

Código com:

- Desenvolvimento de um calendário com os dias da semana (em português)
- LEFT JOIN entre o calendário e a tabela de vendas agregação de vendas por dia (soma de valor_venda), substituição de valores nulos por zero para dias sem vendas

Questão 5.2 - Explique:

1. Por que é necessário utilizar uma tabela de datas (calendário) em vez de agrupar diretamente a tabela de vendas?
2. O que aconteceria com a média de vendas se um dia da semana tivesse muitos dias sem nenhuma venda registrada?

Questão 6 - Previsão de demanda

Cenário

O Sr. Almir está furioso. No último verão, o estoque de "Coletes Salva-Vidas" acabou em 3 meses, e a empresa perdeu milhares de reais em vendas. Por outro lado, compraram "Âncoras" demais e elas estão enferrujando no galpão. Gabriel Santos, o Tech Lead, disse que não dá mais para confiar no "feeling". Ele quer um modelo preditivo que diga exatamente quantas unidades venderemos no próximo mês para ajustar as compras com fornecedores.

Premissas obrigatórias:

- O período de treino deve incluir dados até 31/12/2025.
- O período de teste deve ser o primeiro trimestre de 2026.
- A previsão deve ser feita em base mensal.
- Considere apenas o produto: "Bússola de Bordo 702"

Tarefa:

1. Utilize os datasets [products.csv](#), [product_variants](#), [orders.csv](#) e [order_items.csv](#) para criar um dataset unificado que facilite a criação do modelo preditivo.
2. Construa um modelo baseline simples, utilizando: Média móvel dos últimos 3 meses de vendas (considerando apenas dados anteriores à data prevista).
3. Gere a previsão mensal de vendas para o primeiro trimestre de 2026.
4. Compare as previsões com os valores reais do período de teste utilizando a métrica: MAE (Mean Absolute Error)
5. Responda objetivamente:
 - a. O baseline é adequado para esse produto?
 - b. Cite uma limitação desse método.

Questão 6.1 - Código em python

Adicione o código python usado para construção do modelo.

Questão 6.2 - Validação

Utilizando seu modelo treinado, qual é a soma total da previsão de vendas (arredondada para número inteiro) para o 'Bússola de Bordo 702' durante o primeiro trimestre de 2026?

Questão 6.3 - Explique:

1. Como o baseline foi construído?
2. Como evitou data leakage?
3. Uma limitação do modelo proposto.

Questão 7 - Sistema de recomendação

Cenário

A Marina percebeu que clientes que compram lanchas quase sempre esquecem de levar a defesa (proteção lateral). Ela quer implementar uma vitrine de "Quem comprou isso, também levou..." no site.

Como não temos ferramentas de Big Data caras, você precisará criar um motor de recomendação, baseado na similaridade de compra dos clientes.

Identificar qual produto deve ser recomendado junto ao item "Motor de Popa 1949", com base na similaridade de comportamento de compra dos clientes.

Tarefa:

1. Crie uma matriz de interação Usuário × Produto obedecendo às regras abaixo:
 - a. Linhas: id_cliente
 - b. Colunas: id_produto
 - c. Valor da célula:
 - d. 1 se o cliente comprou ao menos uma vez o produto
 - e. 0 caso contrário
 - f. Ignore a quantidade comprada (presença/ ausência apenas)
2. Cálculo de Similaridade entre Produtos
 - a. Calcule a Similaridade de Cosseno (Cosine Similarity) entre os vetores dos produtos
 - b. A similaridade deve ser calculada produto × produto, com base nos clientes que compraram cada item
3. Ranking de Produtos Similares
 - a. Considere o produto "Motor de Popa 1949" como item de referência
 - b. Gere um ranking com os nomes dos 5 produtos mais similares a ele
 - c. Desconsidere o próprio motor no ranking

Questão 7.1 - Código em python

Script em python que:

- Constrói a matriz usuário–item
- Calcula a similaridade de cosseno
- Gera o ranking de similaridade
- Bibliotecas permitidas:
 - pandas
 - numpy
 - sklearn (opcional, para cosine similarity)

Questão 7.2 - Validação

Qual é o nome do produto com MAIOR similaridade ao "Motor de Popa 1949"?

Questão 7.3 - Explique:

1. Como a matriz foi construída?
2. O que significa a similaridade de cosseno nesse contexto?
3. Uma limitação desse método de recomendação.

Projeção de carreira:

Em qual questão você teve mais facilidade? E em qual questão você mais gostou de trabalhar?

- Questão 1 - EDA
- Questão 2 - Schema
- Questão 3 - Carregamento
- Questão 4 - Análise de clientes
- Questão 5 - Dimensão de calendário
- Questão 6 - Previsão de demanda
- Questão 7 - Sistema de recomendação

Além das respostas objetivas, você deve enviar um material complementar (**dashboard obrigatório**) com o objetivo de apresentar sua visão analítica sobre os dados trabalhados no desafio.

Você também pode enviar outros materiais que você tenha usado ao longo da sua construção. A ideia é que você tenha liberdade para explorar os dados e comunicar os principais achados de forma estruturada, como faria em um contexto real de trabalho.

O que **deve** ser entregue:

- Dashboard (Power BI, Looker Studio, Tableau, etc.)

O que também **pode** ser entregue:

Você também pode escolher o formato que preferir, por exemplo:

- Notebook comentado
- Relatório em PDF ou apresentação
- Documento com análises e insights